

政治学方法論 II

第3回：1変量のモデル

矢内 勇生

法学部・法学研究科

2015 年 4 月 22 日



神戸大学

今日の内容



- 1 変量のベイズ推定
 - ベイズルールを利用した推定
 - 例：二項分布の母数の推定

- 2 正規分布の平均値の推定
 - 観測値が1つの場合
 - 観測値が複数ある場合



ベイズデータ分析の手順

- ① リサーチクエスチョンに答えられるデータを特定する
- ② 特定したデータを記述する確率モデルを作る
- ③ 推定する母数の事前分布を特定する
- ④ ベイズルールに従い、情報を更新する
- ⑤ 事後予測分布がデータにフィットしているか確かめる

情報の更新



$p(\theta|y)$: θ の事後分布 **これを知りたい！**

ベイズルール

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)} = \frac{L(\theta|y)p(\theta)}{p(y)} \quad (1)$$

$$\propto p(y|\theta)p(\theta) = L(\theta|y)p(\theta) \quad (2)$$

ベイズルールの基本

θ の事後分布 $\propto \theta$ の尤度 $\times \theta$ の事前分布



ベイズ推定に必要なもの

- $p(\theta)$: θ の事前分布 (prior)
- $p(y|\theta) = L(\theta|y)$: y のサンプリングモデル (データ生成過程)、 θ の尤度関数
- $p(y)$: y の事前予測分布 (prior predictive)



問題の設定

二項分布 (binomial distribution) の成功確率の推定

一連のベルヌーイ試行の結果から、成功確率 θ を推定する

- 観測データ（実現値）： $y_i \in \{0, 1\}$, for $i = 1, 2, \dots, n$
- y_i は互いに独立で同一の分布に従う： y_i は交換可能 (exchangeable)
- 使用するデータ： $y = \sum_{i=1}^n y_i$

データを記述する確率モデル



データ生成の確率モデル、サンプリングモデル、DGP

DGP : $y_i \stackrel{\text{iid}}{\sim} \text{Bern}(\theta)$

$$p(y|\theta) = \text{Bin}(y|n, \theta) \quad (3)$$

$$= \binom{n}{y} \theta^y (1 - \theta)^{n-y} \quad (4)$$

$$\propto \theta^y (1 - \theta)^{n-y} \quad (5)$$

θ の事前分布を特定する



- θ についての事前知識が（あまり）ないとする
- θ 自体が確率： $0 \leq \theta \leq 1$
- 区間 $[0, 1]$ は同様に確からしい（特定の値に他の値よりも大きな信頼をおく根拠が無い）
- 区間 $[0, 1]$ の連続型一様分布

$$\theta \sim U(0, 1) \quad (6)$$

$$p(\theta) = U(\theta|0, 1) = 1 \quad (7)$$

ベイズルールに従い、情報を更新する

 θ の事後分布 $\propto \theta$ の尤度 $\times \theta$ の事前分布

$$p(\theta|y) \propto p(y|\theta)p(\theta) \quad (8)$$

$$\propto \theta^y(1-\theta)^{n-y} \quad (9)$$

$$\propto \theta^{(y+1)-1}(1-\theta)^{(n-y+1)-1} \quad (10)$$



ベータ分布 (beta distributions)

ベータ分布の PDF ($0 \leq x \leq 1$)

$$p(x|\alpha, \beta) = \text{Beta}(x|\alpha, \beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\int_0^1 u^{\alpha-1}(1-u)^{\beta-1} du} \quad (11)$$


$$= \frac{1}{B(\alpha, \beta)} x^{\alpha-1}(1-x)^{\beta-1} \quad (12)$$

パラメタ： $\alpha > 0, \beta > 0$

$$E(X) = \frac{\alpha}{\alpha + \beta}$$

$$\text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

例：二項分布の母数の推定





二項分布の母数 θ の事後分布

$$p(\theta|y) \propto \theta^{(y+1)-1} (1-\theta)^{(n-y+1)-1}$$

よって、

$$\theta|y \sim \text{Beta}(y+1, n-y+1)$$

したがって、

$$E(\theta|y) = \frac{y+1}{(y+1) + (n-y+1)} = \frac{y+1}{n+2}$$

$$\text{var}(\theta|y) = \frac{(y+1)(n-y+1)}{(n+2)^2(n+3)}$$

事後情報：事前情報とデータの間



- ベイズ推定：事前情報とデータの折り合いをつける
- 事後情報：事前情報とデータの加重平均
- 重み：データのサイズが大きいほど、データの重みが増す
- サンプルサイズが十分大きくなると、事前情報の重みは取るに足らないものに
- ただし、事前情報で確率 0 が与えられた点は、事後分布から除外される：データサイズが大きくても、事前分布には意味がある

実習：授業用 [GitHub リポジトリ](#) にある `fair-coin.R` を使って、ベイズ分析の基本を理解しよう！



データの確率モデルの特定

- 1 つの観測値 y
- サンプルングモデル：

$$y \sim N(\theta, \sigma^2)$$

観測値が 1 つの場合の θ の尤度

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y-\theta)^2}{2\sigma^2} \right] \quad (13)$$



事前分布の特定

- θ の事前情報
- アップデートすることを見越して、計算しやすい事前分布を考える：尤度と同族を使う
- 正規分布：指数分布族
- 事前分布も指数分布族で特定する

$$\theta \sim N(\mu_0, \tau_0^2)$$

θ の事前分布

$$p(\theta) = \frac{1}{\sqrt{2\pi\tau_0^2}} \exp\left[-\frac{(\theta - \mu_0)^2}{2\tau_0^2}\right] \quad (14)$$



情報の更新

$$p(\theta|y) \propto p(y|\theta)p(\theta) \quad (15)$$

$$\propto \exp \left[-\frac{1}{2} \left\{ \frac{(y-\theta)^2}{\sigma^2} + \frac{(\theta-\mu_0)^2}{\tau_0^2} \right\} \right] \quad (16)$$

$$\propto \exp \left[-\frac{1}{2\tau_1^2} (\theta - \mu_1)^2 \right] \quad (17)$$

ただし、

$$\mu_1 = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{1}{\sigma^2} y}{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}}, \quad \frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

したがって、 $\theta|y \sim N(\mu_1, \tau_1^2)$



データの確率モデル

- 観測値： $y = (y_1, y_2, \dots, y_n)$
- サンプルングモデル：

$$y_i \stackrel{\text{iid}}{\sim} N(\theta, \sigma^2)$$

データ y に対する θ の尤度関数

$$p(y|\theta) = \prod_{i=1}^n p(y_i|\theta) \quad (18)$$

$$\propto \prod_{i=1}^n \exp \left[-\frac{(y_i - \theta)^2}{2\sigma^2} \right] \quad (19)$$



事前分布と事後分布

- 事前分布：観測値が1つのときと同じ

$$p(\theta) \propto \exp \left[-\frac{(\theta - \mu_0)^2}{2\tau_0^2} \right]$$

$$p(\theta|y) \propto p(\theta)p(y|\theta) \quad (20)$$

$$\propto \exp \left[-\frac{(\theta - \mu_0)^2}{2\tau_0^2} \right] \prod_{i=1}^n \exp \left[-\frac{(y_i - \theta)^2}{2\sigma^2} \right] \quad (21)$$

$$\propto \exp \left[-\frac{1}{2} \left\{ \frac{1}{\tau_0^2} (\theta - \mu_0)^2 + \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \theta)^2 \right\} \right] \quad (22)$$

事後分布は $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ を通じてのみ y に依存する！



十分統計量 (sufficient statistic)

- 現在検討中のデータ：すべての y_i ではなく、 \bar{y} だけ考えればよい

十分統計量

x について統計量 $t = t(x)$ が、以下の条件を満たすとき、 t を x が与えられた条件下での θ に対する十分統計量と呼ぶ

$$p(x|\theta) = p(t|\theta)p(x|t) \quad (23)$$

- 現在検討中の問題： \bar{y} は θ に対する十分統計量である



十分統計量を使って問題を捉え直す

- \bar{y} という観測値が1つあると考える
- サンプルングモデル： $\bar{y} \sim N(\theta, \frac{\sigma^2}{n})$

したがって、

$$p(\theta|y_1, \dots, y_n) = p(\theta|\bar{y}) = N(\theta|\mu_n, \tau_n^2)$$

ただし、

$$\mu_n = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{n}{\sigma^2} \bar{y}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \quad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

- n が一定で $\tau_0 \rightarrow \infty$ のとき、または t_0 が一定で $n \rightarrow \infty$ のとき、

$$p(\theta|y) \approx N\left(\theta|\bar{y}, \frac{\sigma^2}{n}\right)$$