

政治学方法論 II

第 8 回：階層モデル

矢内 勇生

法学部・法学研究科

2015 年 6 月 3 日



神戸大学

今日の内容



- ① 階層モデル 1：二項分布モデル
 - 共役階層モデルのベイズ推定
 - ネズミの腫瘍実験：Section 5.1 の例 (pp.102–104)

- ② 階層モデル 2：正規分布モデル
 - 交換可能な母数を正規分布モデルで推定する

階層モデル



例: ネズミの腫瘍実験で考える

- 尤度: $p(y|\theta)$
- 母数分布: 自然な共役自然分布 $p(\theta|\phi)$
- 超事前分布: $p(\phi)$
- 同時事後分布:

$$p(\theta, \phi|y) \propto p(y|\theta, \phi)p(\theta, \phi) \quad (1)$$

$$= p(y|\theta)p(\theta, \phi) \quad (2)$$

- 解析と数値計算の両者を使って事後分布を求めてみよう!



解析によって条件付き分布と周辺分布を求める

- ① 同時事後分布 $p(\theta, \phi|y)$ を、尤度、母数分布、超事前分布を使って表す
- ② 条件付き確率、 $p(\theta|\phi, y)$ を求める

$$p(\theta|\phi, y) = \prod_{j=1}^J p(\theta_j|\phi, y) \quad (3)$$

- ③ $p(\phi|y)$ をベイズルールによって求める

$$p(\phi|y) = \int p(\theta, \phi|y) d\theta \quad (4)$$

or

$$p(\phi|y) = \frac{p(\theta, \phi|y)}{p(\theta|\phi, y)} \quad (5)$$

シミュレーションによって事後分布を抽出する



- ① $p(\phi|y)$ からベクトル ϕ を引く
- ② 抽出した ϕ を基に、 $p(\theta|\phi, y)$ からベクトル θ を引く：
 $p(\theta|\phi, y) = \prod_j p(\theta_j|\phi, y)$ だから、 θ_j を1つずつ引けばよい
- ③ 抽出した ϕ を基に、事後予測値 \tilde{y} を引く

この作業を L 回繰り返せば、事後分布が得られる



ネズミの腫瘍実験を分析する

- y_j : 実験 j において、 n_j 匹のネズミのうち、腫瘍をもったネズミの数
- $j = 1, \dots, J, J = 71$
- サンプルングモデル (尤度):

$$y_j \sim \text{Bin}(n_j, \theta_j)$$

- θ_j はベータ分布から独立に生まれるとする:

$$\theta_j \sim \text{Beta}(\alpha, \beta)$$

- (α, β) については特別な情報がないので、無情報超事前分布を使う



解析 1: 同時事後分布

$$\begin{aligned}
 p(\theta, \alpha, \beta | y) &\propto p(\alpha, \beta) p(\theta | \alpha, \beta) p(y | \theta, \alpha, \beta) \\
 &\propto p(\alpha, \beta) \\
 &\quad \times \prod_{j=1}^J \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \Gamma(\beta)} \theta_j^{\alpha-1} (1 - \theta_j)^{\beta-1} \\
 &\quad \times \prod_{j=1}^J \theta_j^{y_j} (1 - \theta_j)^{n_j - y_j}
 \end{aligned}$$

- ただし、 $\Gamma(\cdot)$ はガンマ関数

$$\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt$$

- 自然数 n について、

$$\Gamma(n+1) = n!$$

解析 2： θ の条件付き分布

$$\theta_j | \alpha, \beta, y \sim \text{Beta}(\alpha + y_j, \beta + n_j - y_j)$$

$$p(\theta | \alpha, \beta, y) = \prod_{j=1}^J \frac{\Gamma(\alpha + \beta + n_j)}{\Gamma(\alpha + y_j) \Gamma(\beta + n_j - y_j)} \theta_j^{\alpha + y_j - 1} (1 - \theta_j)^{\beta + n_j - y_j - 1}$$

解析 3: (α, β) の周辺事後分布

$$\begin{aligned}
 p(\alpha, \beta | y) &= \frac{p(\theta, \alpha, \beta | y)}{p(\theta | \alpha, \beta, y)} \\
 &\propto p(\alpha, \beta) \prod_{j=1}^J \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + y_j)\Gamma(\beta + n_j - y_j)}{\Gamma(\alpha + \beta + n_j)}
 \end{aligned}$$



$p(\alpha, \beta)$ の設定 (1)

- 超事前分布 (α, β) を選びたい
- θ_j が従うベータ分布の平均とサンプルサイズによって特定する
- 平均: $\alpha/(\alpha + \beta)$
- サンプルサイズ: $\alpha + \beta$
- 無情報: $(-\infty, \infty)$ で考えたい
- しかし . . .

$$0 < \frac{\alpha}{\alpha + \beta} < 1, \quad \alpha + \beta > 0$$

- 変数変換する!



$p(\alpha, \beta)$ の設定 (2)

- $(0, 1) \rightarrow (-\infty, \infty)$ にする変換: ロジット変換

$$\text{logit}\left(\frac{\alpha}{\alpha + \beta}\right) = \log\left(\frac{\frac{\alpha}{\alpha + \beta}}{1 - \frac{\alpha}{\alpha + \beta}}\right) = \log\left(\frac{\alpha}{\beta}\right)$$

- $(0, \infty) \rightarrow (-\infty, \infty)$ にする変換: 対数変換

$$\log(\alpha + \beta)$$

- $p(\log(\alpha/\beta), \log(\alpha + \beta)) \propto 1$ とする
- 残念ながら、この超事前分布は improper な事後分布を生む: 使えない



$p(\alpha, \beta)$ の設定 (3)

- 代わりに、次のように設定する

$$p\left(\frac{\alpha}{\alpha + \beta}, (\alpha + \beta)^{-\frac{1}{2}}\right) \propto 1$$

- ヤコビアンを求めて変換する:

$$p(\alpha, \beta) \propto (\alpha + \beta)^{-\frac{5}{2}}$$

- これをさらに変換すると、


$$p\left(\log\left(\frac{\alpha}{\beta}\right), \log(\alpha, \beta)\right) \propto \alpha\beta(\alpha + \beta)^{-\frac{5}{2}}$$



事後分布の抽出

- 超事前分布が設定できたので、 $p(\alpha, \beta | y)$ より (α, β) を抽出する
- (α, β) が抽出できれば、 $p(\theta_j | \alpha, \beta, y)$ が特定できるので、 θ_j を抽出する
- この作業を繰り返し、 θ_j の事後分布を得る
- 導出の詳細は授業のウェブサイトで

推定値の収縮 (shrinkage)





問題の設定

- J 個の独立した集団 (実験)
- 集団 $j = 1, \dots, J$ における n_j 個の観測値 y_{ij} から θ_j を推定する
- 誤差の分散 σ^2 は既知であるとする

$$y_{ij} | \theta_j \sim N(\theta_j, \sigma^2),$$

for $i = 1, \dots, n_j; j = 1, \dots, J$

- 集団 j における観測値の平均値とその分散は、

$$\bar{y}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij}, \quad \sigma_j^2 = \frac{\sigma^2}{n_j}$$

尤度 (サンプリングモデル)



- 十分統計量: $\bar{y}_{\cdot j}$
- 十分統計量を使って θ_j の尤度を表すと、

$$\bar{y}_{\cdot j} | \theta_j \sim N(\theta_j, \sigma_j^2)$$

- σ^2 と n_j が既知なので、 σ_j^2 も既知



理に適った推定値は？

$\theta = (\theta_1, \dots, \theta_J)$ の事後分布について、どんな推定値なら受け入れられそう？

- 集団ごとの平均値 (no pooling / complete separating)

$$\bar{y}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij}$$

- 全体の平均値 (complete pooling)

$$\bar{y}_{..} = \frac{\sum_{j=1}^J \frac{1}{\sigma_j^2} \bar{y}_{\cdot j}}{\sum_{j=1}^J \frac{1}{\sigma_j^2}}$$

- 「伝統的な」方法：ANOVA によってどちらか選ぶ (BDA3: p.114 参照)
 - 集団間の変動 (between variance) が集団内の変動 (withing variance) に対して大きい (F 検定) とき：no pooling
 - それ以外：complete pooling

交換可能な母数を正規分布モデルで推定する

折衷案: partial pooling



- Bayesian: no pooling と complete pooling を組み合わせる

$$\hat{\theta}_j = \lambda_j \bar{y}_{\cdot j} + (1 - \lambda) \bar{y}_{\cdot \cdot},$$

ただし、 $\lambda_j \in [0, 1]$

- これを実現する事前分布
 - ① 独立な $\theta_j \sim U(-\infty, \infty) \rightarrow \lambda_j = 1$: no pooling
 - ② $\theta_1 = \dots = \theta_j = \theta \sim U(\alpha, \beta) \rightarrow \lambda_j = 0$: complete pooling
 - ③ $\theta_j \stackrel{\text{iid}}{\sim} N(\mu_0, \sigma_0^2) \rightarrow \lambda_j \in [0, 1]$: partial pooling
- No pooling と complete pooling は partial pooling の特殊ケース

交換可能な母数を正規分布モデルで推定する



階層モデル

- $\theta_j \stackrel{\text{iid}}{\sim} N(\mu, \tau^2)$ と仮定する
- 超母数: μ, τ
- θ_j は (μ, τ) が与えられたときに条件付き独立

$$p(\theta_1, \dots, \theta_J | \mu, \tau) = \prod_{j=1}^J N(\theta_j | \mu, \tau^2)$$

$$p(\theta_1, \dots, \theta_J) = \int \prod_{j=1}^J [N(\theta_j | \mu, \tau^2)] p(\mu, \tau) d(\mu, \tau)$$

- τ が所与のときの μ の超事前分布を無情報と仮定する

$$p(\mu, \tau) = p(\mu | \tau) p(\tau) \propto p(\tau)$$



同時事後分布

- 十分統計量 $\bar{y}_{\cdot j}$ を使って同時事後分布を表す

$$\begin{aligned}
 p(\theta, \mu, \tau | y) &\propto p(\mu, \tau) p(\theta | \mu, \tau) p(y | \theta) \\
 &\propto p(\mu, \tau) \prod_{j=1}^J \text{N}(\theta_j | \mu, \tau^2) \prod_{j=1}^J \text{N}(\bar{y}_{\cdot j} | \theta_j, \sigma_j^2)
 \end{aligned}$$

交換可能な母数を正規分布モデルで推定する



θ_j の条件付き事後分布

- (μ, τ) が与えられたとき、各 θ_j は独立
- θ_j の条件付き事後分布は、

$$\theta_j | \mu, \tau, y \sim N(\hat{\theta}_j, V_j)$$

ただし、

$$\hat{\theta}_j = \frac{\frac{1}{\sigma_j^2} \bar{y}_{\cdot j} + \frac{1}{\tau^2} \mu}{\frac{1}{\sigma_j^2} + \frac{1}{\tau^2}}, \quad V_j = \frac{1}{\frac{1}{\sigma_j^2} + \frac{1}{\tau^2}}$$

- 事後分布の平均は、データの平均と事前分布の平均の精度 (precision) を重みとする加重平均
- 事後分布の精度は、データの精度と事前分布の精度の和

交換可能な母数を正規分布モデルで推定する

超母数の周辺事後分布



- 完全なベイズ推定のために、 (μ, τ) を母数として扱う
- データから得られる情報を使って超母数の分布を得る

$$p(\mu, \tau | y) \propto p(y | \mu, \tau) p(\mu, \tau)$$

- 一般的には、 $p(y | \mu, \tau)$ が特定できない：この方法は使えない
- 正規分布モデルの場合は特定できる

$$\bar{y}_{\cdot j} | \mu, \tau \sim N(\mu, \sigma_j^2 + \tau^2)$$

- 超母数の周辺事後分布は、

$$p(\mu, \tau | y) \propto p(\mu, \tau) \prod_{j=1}^J N(\bar{y}_{\cdot j} | \mu, \sigma_j^2 + \tau^2)$$



μ の条件付き事後分布

- τ が与えられたときの μ の条件付き事前分布を一様分布とする

$$p(\mu|\tau) \propto 1$$

- 超母数 τ が与えられたときの μ の条件付き事後分布は、

$$p(\mu|\tau, y) \propto p(\mu|\tau)p(y|\mu, \tau) \propto p(y|\mu, \tau)$$

- したがって、 μ の条件付き事後分布は正規分布に従う

$$\mu|\tau, y \sim N(\hat{\mu}, V_{\mu})$$

ただし、

$$\hat{\mu} = \frac{\sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau_2} \bar{y}_{\cdot j}}{\sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau_2}}, \quad V_{\mu} = \frac{1}{\sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau^2}}$$

交換可能な母数を正規分布モデルで推定する



τ の事後分布

- τ の事後分布は、

$$p(\tau|y) = \frac{p(\mu, \tau|y)}{p(\mu|\tau, y)}$$

$$\propto \frac{p(\tau) \prod_{j=1}^J N(\bar{y}_{\cdot j} | \mu, \sigma_j^2 + \tau^2)}{N(\mu | \hat{\mu}, V_\mu)}$$

- $\mu = \hat{\mu}$ としてさらに簡略化する

$$p(\tau|y) \propto \frac{p(\tau) \prod_{j=1}^J N(\bar{y}_{\cdot j} | \hat{\mu}, \sigma_j^2 + \tau^2)}{N(\hat{\mu} | \hat{\mu}, V_\mu)}$$

$$\propto p(\tau) V_\mu^{\frac{1}{2}} \prod_{j=1}^J (\sigma_j^2 + \tau^2)^{-\frac{1}{2}} \exp \left(-\frac{(\bar{y}_{\cdot j} - \hat{\mu})^2}{2(\sigma_j^2 + \tau^2)} \right)$$



τ の事前分布を設定する

- τ の事前分布を設定する
- 無情報分布を仮定、

$$p(\tau) \propto 1$$

- 超事前分布が improper なので、事後分布が proper になるかどうか確認する必要がある
- $p(\log \tau) \propto 1$ にすると、事後分布は improper になってしまう



事後分布をシミュレートする

- 事後分布は以下のとおり分解できる

$$p(\theta, \mu, \tau | y) = p(\tau | y) p(\mu | \tau, y) p(\theta | \mu, \tau, y)$$

- ここまでの分析で、右辺の各要素がわっている：シミュレーションで事後分布を求める
 - ① τ を抽出する
 - ② 抽出した τ を用い、 μ を抽出する
 - ③ 抽出した (μ, τ) を使い、 θ を抽出する
 - ④ これを各集団 j に対して行う
 - ⑤ 一連の抽出を L 回行い、事後分布を得る